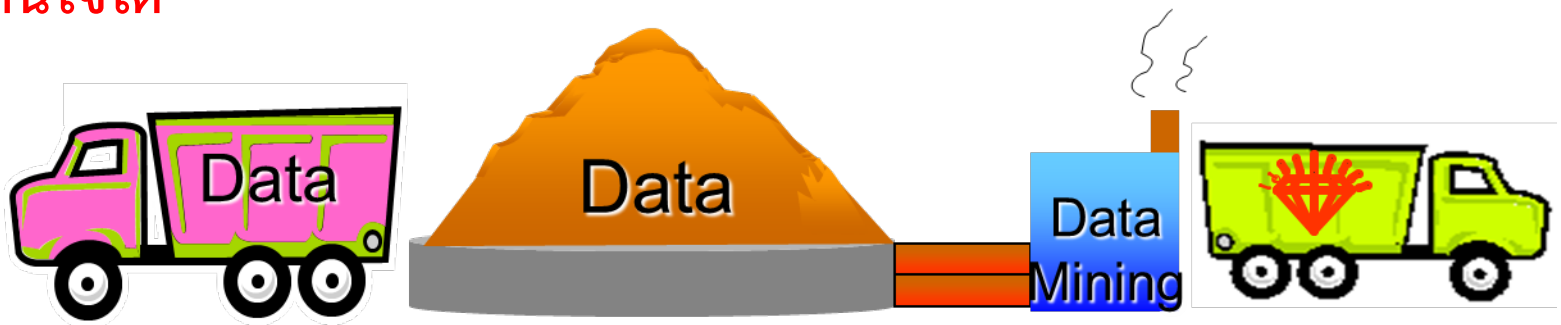
FOUNDATIONS OF BUSINESS INTELLIGENCE:
Data Mining

Data Mining

- เป็นกระบวนการวิเคราะห์ข้อมูล เพื่อค้นหาสารสนเทศ และความรู้ที่ซ่อนอยู่ในฐานข้อมูลขนาดใหญ่ เพื่อนำความรู้ที่ได้ไปใช้ประโยชน์และสนับสนุนการตัดสินใจ
- เป็นกระบวนการ (Process) ที่ใช้เทคนิคทางสถิติ Machine Learning และปัญญาประดิษฐ์ (AI) ในการค้นหารูปแบบ (Patterns) แนวโน้ม (Trends) และความสัมพันธ์ (Relationships) ที่ซ่อนอยู่ในชุดข้อมูลเพื่อค้นพบสารสนเทศและความรู้ที่ไม่เคยทราบมาก่อน โดยสารสนเทศและความรู้ที่ได้จะมีเหตุผลและสามารถนำไปใช้ประโยชน์และสนับสนุนการตัดสินใจได้



การประยุกต์ใช้ Data Mining

1. Market Management

- ### Purchasing Pattern Over Time

วิเคราะห์รูปแบบการซื้อของลูกค้าในช่วงเวลาต่างๆ เพื่อวางแผนการขายสินค้าและบริหารสินค้าคงคลัง

- ### Cross Selling

ค้นหาสินค้าที่มักถูกซื้อร่วมกัน เพื่อแนะนำสินค้าที่เกี่ยวข้องและเพิ่มโอกาสในการขาย

- ### Direct Mail Campaign

วิเคราะห์และแบ่งกลุ่มลูกค้า เพื่อเลือกกลุ่มเป้าหมายและส่งข้อเสนอทางการตลาดให้ตรงกับความสนใจ

2. Risk Analysis and Management

- **Forecasting:** การพยากรณ์ยอดขายและความต้องการสินค้า โดยใช้ข้อมูลในอดีตและข้อมูลปัจจุบันเพื่อคาดการณ์แนวโน้มในอนาคต
- **Credit Scoring:** การวิเคราะห์ข้อมูลผู้ขอสินเชื่อเพื่อประเมินความเสี่ยงด้านเครดิตและความสามารถในการชำระหนี้ เพื่อสนับสนุนการตัดสินใจอนุมัติสินเชื่อ
- **Profile of Attrition(Customer Churn Management):** การวิเคราะห์ปัจจัยและรูปแบบที่สัมพันธ์กับการเลิกใช้บริการของลูกค้า เพื่อระบุกลุ่มลูกค้าที่มีแนวโน้มเลิกใช้บริการและวางแผนรักษาลูกค้า

3. Fraud Detection and Management

วิเคราะห์รูปแบบธุรกรรมเพื่อค้นหารายการที่ผิดปกติ

4. Web Mining

วิเคราะห์ข้อมูลจากเว็บไซต์ เช่น เนื้อหาเว็บไซต์ โครงสร้างลิงก์ และพฤติกรรมการใช้งาน เพื่อนำไปปรับปรุงเว็บไซต์และประสบการณ์ผู้ใช้

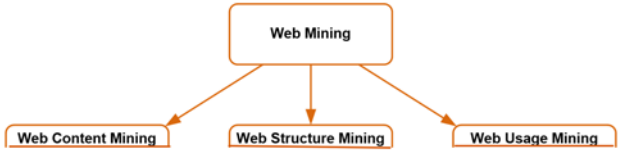
5. Text Mining

วิเคราะห์ข้อความและเอกสารเพื่อค้นหาประเด็นสำคัญ จำแนกข้อความ และวิเคราะห์ความคิดเห็นหรือความรู้สึกของลูกค้า

Web mining

- Web Mining is the application of data mining techniques to discover useful patterns, relationships, and knowledge from web data, including web page content, hyperlink structures, and user interaction records.

- Types of Web Mining



  - Web content mining (การทำเหมืองเนื้อหาเว็บ)

Extracting useful information and knowledge from web page content, such as text, images, and product descriptions.

ตัวอย่าง วิเคราะห์รีวิวสินค้าและความคิดเห็นของลูกค้า (Sentiment Analysis) เพื่อประเมินความพึงพอใจและปรับปรุงสินค้า

  - Web structure mining (การทำเหมืองโครงสร้างเว็บ)

Analyzing the hyperlink structure and relationships among web pages.

ตัวอย่าง: วิเคราะห์หน้าเว็บที่มีความสำคัญจากโครงสร้างลิงก์ และปรับปรุงโครงสร้างเว็บไซต์เพื่อช่วยให้ผู้ใช้ค้นหาข้อมูลได้สะดวกขึ้น

  - Web usage mining (การทำเหมืองพฤติกรรมการใช้งานเว็บ)

Discovering user access and navigation patterns from web usage data, such as server logs, clicks, and browsing sessions.

ตัวอย่าง: วิเคราะห์เส้นทางการซื้อสินค้าเพื่อระบุจุดที่ลูกค้าออกจากเว็บไซต์ และปรับปรุงประสบการณ์ผู้ใช้ (User Experience)

Text mining การทำเหมืองข้อความ

- เป็นกระบวนการสกัดสารสนเทศ รูปแบบ และความรู้ที่สำคัญจากข้อมูลข้อความที่ไม่มีโครงสร้าง (Unstructured Text Data) เพื่อค้นหาประเด็นสำคัญ รูปแบบและความสัมพันธ์ที่ซ่อนอยู่ในข้อมูล และสรุปผลเป็นสารสนเทศและความรู้ที่สามารถนำไปใช้ประโยชน์ได้
- ตัวอย่าง Unstructured Text data: เอกสาร Word, ไฟล์ PDF, อีเมล รีวิวสินค้า และบันทึกการสนทนาที่แปลงเป็นข้อความ
- For example:
  - การทำเหมืองข้อความ วิเคราะห์บันทึกการสนทนากับลูกค้า เพื่อค้นหาปัญหาที่พบบ่อยและระบุประเด็นที่ต้องปรับปรุงการบริการ
  - การจำแนกเอกสารตามหมวดหมู่ เพื่อความสะดวกในการใช้งานและการค้นหา
- Applications
  - Marketing Applications: Improving CRM

วิเคราะห์ความคิดเห็นและความรู้สึกของลูกค้า (Sentiment Analysis) เพื่อปรับปรุงการบริการและเพิ่มประสิทธิภาพการบริหารความสัมพันธ์กับลูกค้า (CRM)

Data Mining Process

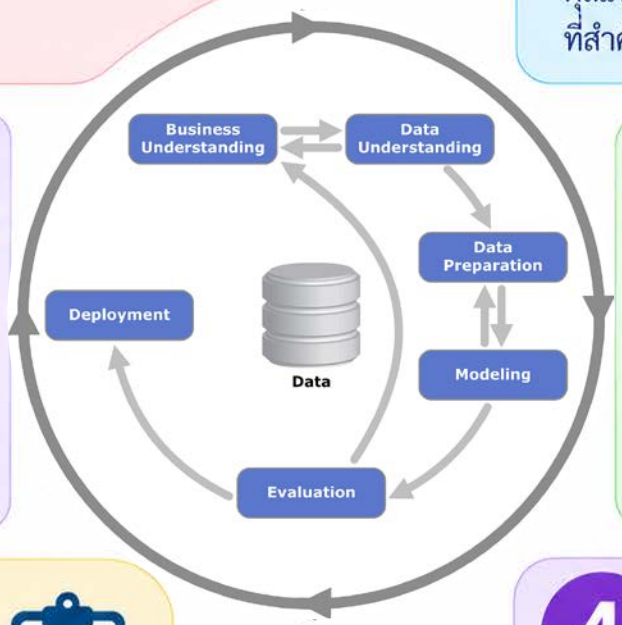
(CRISP-DM : Cross-Industry Standard Process for Data Mining)

1 Business Understanding
(ทำความเข้าใจปัญหาทางธุรกิจ)

ทำความเข้าใจปัญหาทางธุรกิจ กำหนดวัตถุประสงค์และความต้องการของผู้เกี่ยวข้อง กำหนดเกณฑ์ความสำเร็จ และวางแผนการดำเนินงาน

2 Data Understanding
(ทำความเข้าใจข้อมูล)

รวบรวมข้อมูลจากแหล่งต่าง ๆ และสำรวจทำความเข้าใจลักษณะของข้อมูล ตรวจสอบคุณภาพข้อมูล และระบุปัญหาและความสัมพันธ์ที่สำคัญ



3 Data Preparation
(เตรียมข้อมูล)

คัดเลือกข้อมูลที่เกี่ยวข้อง ทำความสะอาดข้อมูล จัดการค่าที่หายไปและค่าผิดปกติ แปลงข้อมูลให้อยู่ในรูปแบบที่เหมาะสม และสร้างตัวแปรใหม่สำหรับการทำเหมืองข้อมูล

4 Modeling
(สร้างแบบจำลอง)

เลือกเทคนิคการทำเหมืองข้อมูลที่เหมาะสม สร้างและฝึกแบบจำลอง ปรับแต่งพารามิเตอร์ และเปรียบเทียบแบบจำลองที่ดีที่สุด

5 Evaluation
(ประเมินผลลัพธ์)

แปลผลลัพธ์และประเมินคุณภาพของแบบจำลอง ตรวจสอบว่าผลลัพธ์สอดคล้องกับวัตถุประสงค์ทางธุรกิจ และพิจารณาว่าควรนำไปใช้งาน ปรับปรุงเพิ่มเติม หรือย้อนกลับไปปรับปรุงขั้นตอนก่อนหน้า

6 Deployment
(นำผลลัพธ์ไปใช้งาน)

สื่อสารผลลัพธ์และข้อค้นพบให้ผู้เกี่ยวข้องเข้าใจ นำแบบจำลองไปใช้งานจริงในระบบหรือกระบวนการทางธุรกิจ ติดตามผลการใช้งานและประสิทธิภาพของแบบจำลอง และปรับปรุงเมื่อข้อมูลหรือสถานการณ์เปลี่ยนแปลง

Data Mining Process

1. Business understanding

- ทำความเข้าใจปัญหาและเป้าหมายทางธุรกิจ เพื่อกำหนดเป้าหมายของโครงการ Data Mining ให้สอดคล้องกับความต้องการขององค์ก
- กิจกรรมสำคัญ
  - ระบุปัญหาและความต้องการทางธุรกิจ
  - กำหนดเป้าหมายทางธุรกิจและเกณฑ์วัดความสำเร็จ
  - แปลงเป้าหมายทางธุรกิจเป็นเป้าหมายการทำเหมืองข้อมูล
- ตัวอย่าง: ร้านค้าออนไลน์
  - ปัญหาทางธุรกิจ: ยอดขายต่อคำสั่งซื้อต่ำกว่าที่วางไว้
  - Business Objective: เพิ่มยอดขายต่อคำสั่งซื้อด้วยการแนะนำสินค้าที่เหมาะสม
  - Data Mining Objective: ค้นหาความสัมพันธ์ระหว่างสินค้าที่ลูกค้ามักซื้อร่วมกัน โดยใช้ Association Rule Mining
  - เกณฑ์วัดความสำเร็จ: ประเมินคุณภาพของกฎความสัมพันธ์ และวัดการเปลี่ยนแปลงของยอดขายหลังทดลองใช้ระบบแนะนำสินค้า

Data Mining Process

2. Data Understanding

ทำความเข้าใจข้อมูลที่มีอยู่ เพื่อประเมินว่าข้อมูลมีลักษณะ คุณภาพ และความเหมาะสมเพียงพอที่จะนำมาใช้ตอบโจทย์ทางธุรกิจที่กำหนดไว้หรือไม่

กิจกรรมสำคัญ

- Collect Initial Data: รวบรวมข้อมูลเบื้องต้นจากแหล่งข้อมูลที่เกี่ยวข้อง
- Describe Data: อธิบายลักษณะข้อมูล เช่น จำนวนระเบียน จำนวนตัวแปร ชนิดข้อมูล และการกระจายตัวของข้อมูล
- Explore Data: สำรวจข้อมูลด้วยสถิติเชิงพรรณนา ตาราง กราฟ และการวิเคราะห์ความสัมพันธ์เบื้องต้น
- Verify Data Quality: ตรวจสอบคุณภาพข้อมูล เช่น ค่าที่หายไป ข้อมูลซ้ำ ค่าผิดปกติ และความไม่สอดคล้องกันของข้อมูล

Data Mining Process

3. Data Preparation

เตรียมข้อมูลให้มีคุณภาพและอยู่ในรูปแบบที่เหมาะสมสำหรับการสร้างโมเดล Data Mining

กิจกรรมสำคัญ แบ่งออกเป็น 3 ขั้นตอนย่อย ดังนี้

1. **Data Selection (การคัดเลือกข้อมูล)** คัดเลือกข้อมูลและตัวแปรที่เกี่ยวข้องกับวัตถุประสงค์ของโครงการ โดยพิจารณาเลือกแหลงข้อมูล ระเบียน (Records) และตัวแปร (Attributes) ที่จำเป็นต่อการวิเคราะห์และสรางโมเดล

   ตัวอย่าง: ต้องการวิเคราะห์ปัจจัยที่เกี่ยวข้องกับการเลือกซื้อรถสปอร์ต จึงคัดเลือกข้อมูลลูกค้าและประวัติการซื้อรถ โดยใช้ตัวแปร เช่น อายุ รายได อาชีพ ยี่หอรถ และประเภทรถ และไม่นำข้อมูลพนักงานขายที่ไม่เกี่ยวของกับโจทย์มาวิเคราะห์

1. **Data Preprocessing (การเตรียมและทำความสะอาดข้อมูล)** เป็นการทำข้อมูลให้มีคุณภาพดี เพื่อให้ขอมูลมีความถูกต่อง ครบถวน และสอดคลองกัน เช่น จัดการ Missing Value, outlier data , ปรับแกขอมูลที่ไมสอดคลองกัน เช่น รูปแบบวันที่หรือหนวยวัดที่แตกตางกัน

3. **Data Transformation (การแปลงข้อมูล)** แปลงข้อมูลให้อยู่ในรูปแบบที่เหมาะสมกับเทคนิคและอัลกอริทึมที่ใช้สรางโมเดล โดยอาจสรางตัวแปรใหม ปรับสเกลขอมูล หรือแปลงคาขอมูลให อยู่ในรูปแบบที่ตองการ

   ตัวอย่าง - สร้างตัวแปรช่วงอายุ เช่น ต่ำกว่า 30 ปี, 30–49 ปี และ 50 ปีขึ้นไป

   - แปลงข้อมูลประเภทรถจากข้อความเป็นตัวเลข

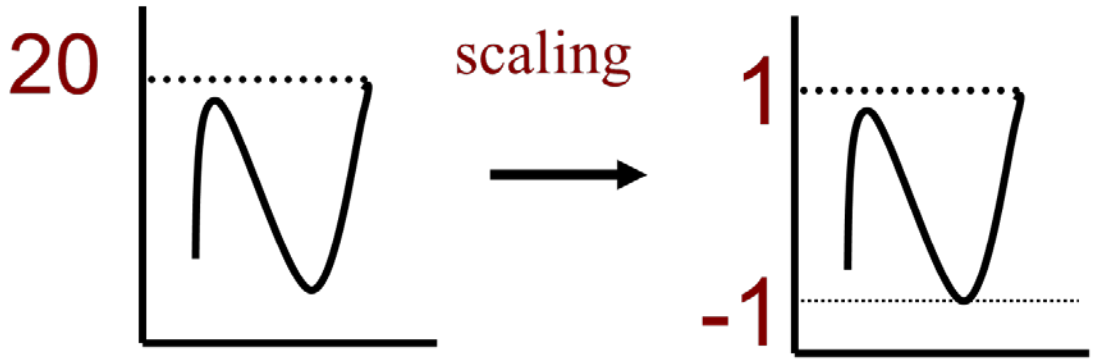
   - ปรับสเกลตัวแปรรายได้ให้อยู่ในช่วง -1 ถึง 1 ด้วย Min-Max Normalization

Data Transformation

- **Normalization:** การนำข้อมูลมาแบ่งภายในช่วงที่กำหนด เช่น 0.0-1.0, -1.0-1.0
  - **min-max normalization**

$$v' = \frac{v - min_A}{max_A - min_A}(new_max_A - new_min_A) + new_min_A$$

min_A และ max_A เป็นค่า Minimum และ Maximum ของแอตทริบิวจะสามารถใช้ Min-Max Normalization แปลงค่า (Map) V ของ A ไปเป็น V' บนช่วง [new_minA,new_maxA]



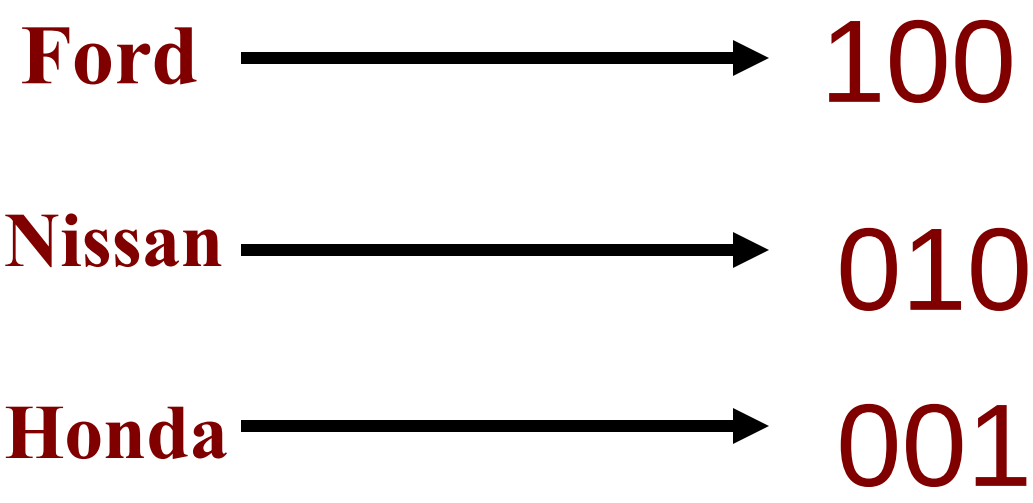
Discretization

- Discretization
  - Involves converting quantitative variables into categorical variables by dividing the values of the input variable into buckets.
  - Ex: Income in range $0-$9999 = range of 1

    $10,000-$19,999 = range of 2

One of N coding

- “One of N coding” involves converting a categorical variable to numeric representation.



Data Mining Process

4. Modeling (การสร้างแบบจำลอง)

เป็นขั้นตอนการเลือกเทคนิคและสร้างแบบจำลอง (Model) โดยเลือกวิธีการให้เหมาะสมกับวัตถุประสงค์ของการทำ Data Mining เพื่อค้นหารูปแบบ (Patterns) แนวโน้ม (Trends) และความสัมพันธ์ (Relationships) ของข้อมูล รวมถึงการนำแบบจำลองไปใช้ในการจำแนกกลุ่ม การพยากรณ์ หรือการค้นหาความสัมพันธ์ของข้อมูล

Data Mining Process

Model ในการทำ Data Mining

1. Predictive Model

makes predictions about the future based on information from the past and present

- Classification เป็นการทำนายว่าสิ่งนั้นควรอยู่ในกลุ่มไหน
  - Decision trees
  - Neural Networks
- Value prediction เป็นการทำนายค่าที่เป็นตัวเลข
  - Linear Regression
  - Neural Networks

Classification

- the process of assigning new objects to predefined categories or classes
- เป็นกระบวนการสร้างแบบจำลองเพื่อจำแนกข้อมูลให้อยู่ในกลุ่มหรือประเภทที่กำหนดไว้ล่วงหน้า โดยเรียนรู้จากข้อมูลที่มีการระบุคลาสไว้แล้ว
- Supervised Learning

EX. A classified data of Credit card customers

No	income	Job Position	age	Class
4	..	..	..	A
5	..	..	..	C
6	..	..	..	A
7	..	..	..	B

Supervised Learning

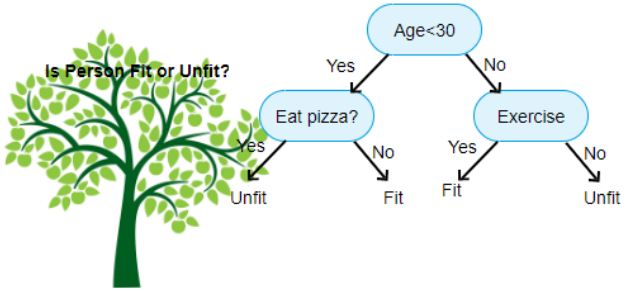
- Supervised Learning เป็นกระบวนการเรียนรู้เพื่อหาความสัมพันธ์ของข้อมูลจากข้อมูล input – output ที่ทราบค่า
- ตัวอย่างข้อมูล

No	income	Job Position	age	Class
1	50000	Manager	40	A
2	18000	worker	24	C
3	60000	Manager	45	A
4	35000	supervisor	30	B

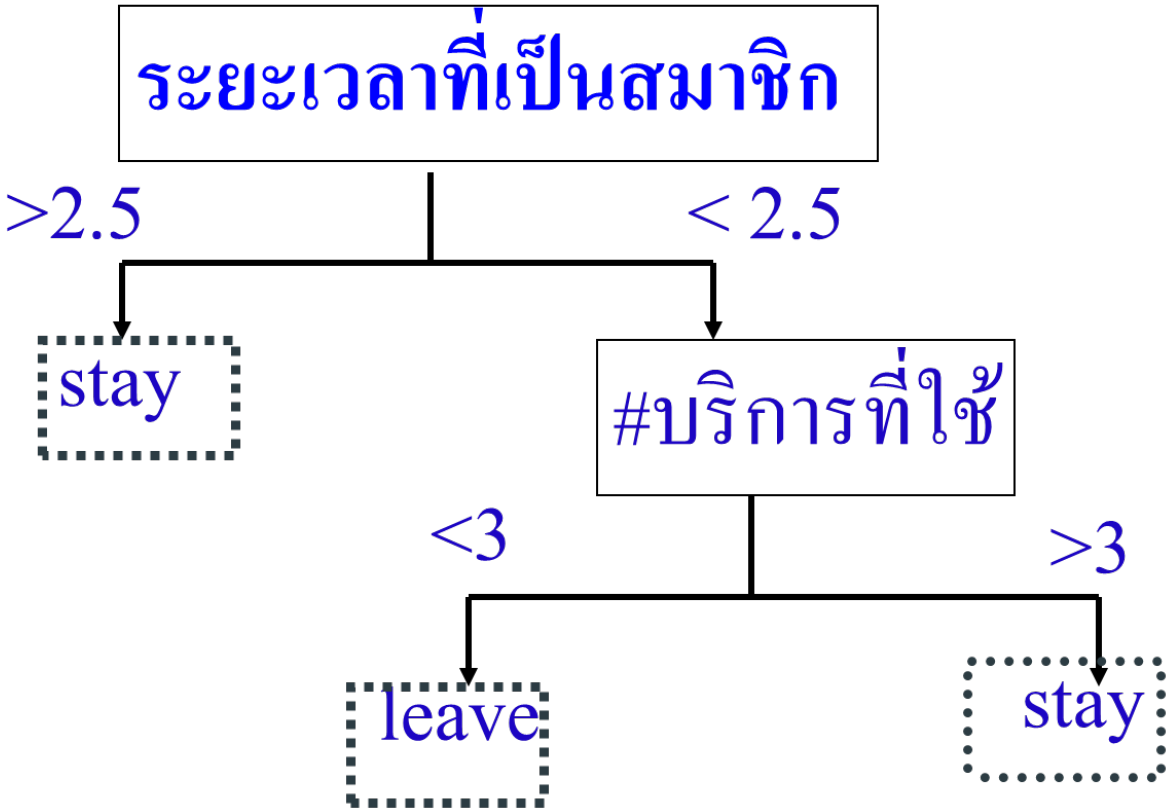
An example of classification

ชื่อ	ระยะเวลาที่เป็นสมาชิก	# บริการที่ใช้	สถานะ
A	>2.5	>3	Stay
B	>2.5	<3	Stay
C	<2.5	<3	Leave
D	<2.5	>3	Stay

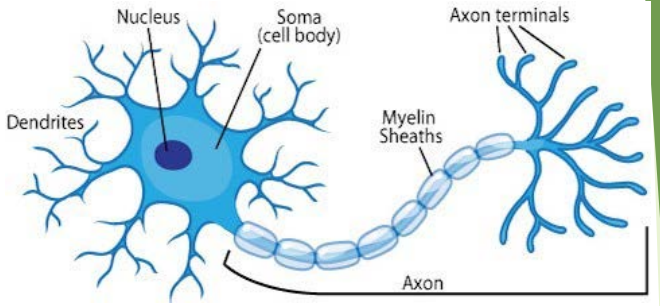
An example of classification by decision tree

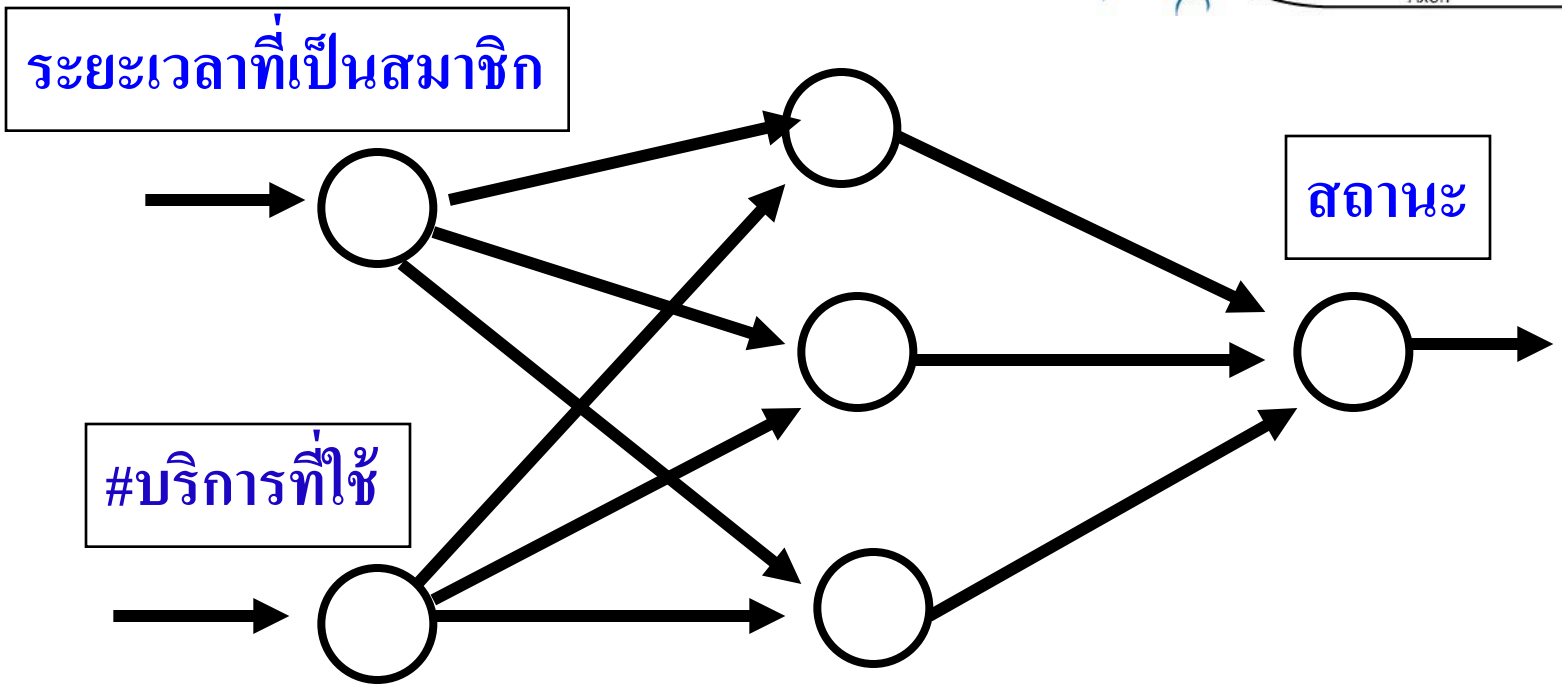


Decision Tree เป็นโมเดลที่ใช้ในการ Classifies ข้อมูลตาม Nodes และ Leaves ที่มีความสัมพันธ์กันตามเงื่อนไข โดยสามารถแตกความสัมพันธ์ลงไปจนสามารถพบสิ่งที่ต้องการ

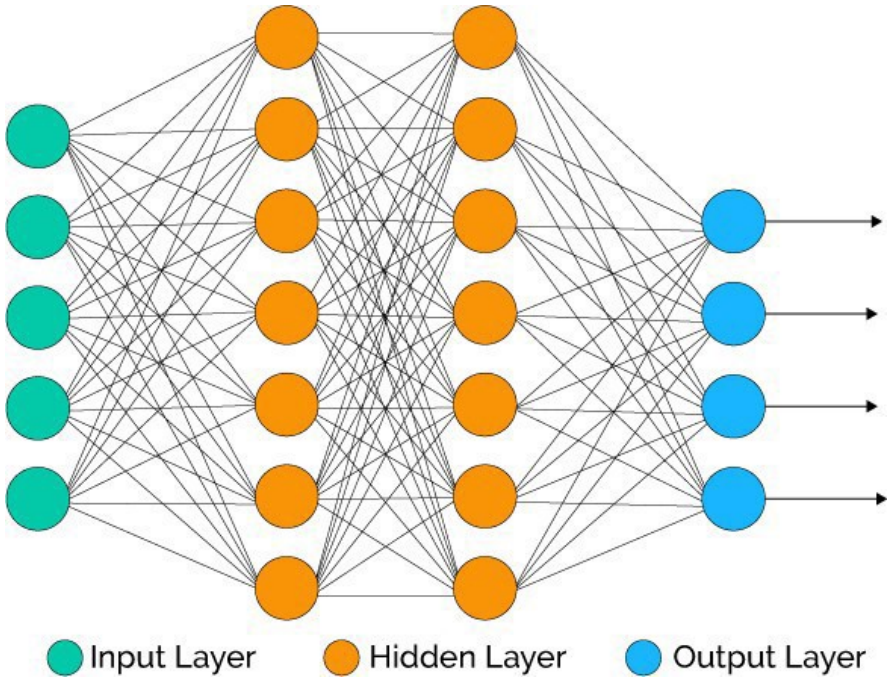


Example of classification by using neural networks





Neural Networks



Data Mining Process

Value prediction

Regression

- Learning a function that maps input features to a continuous numerical value.

EX. A prediction model of car accident probability

No	Vehicle speed (mph)	Alcohol level	age	Probability of Car Accident
1	80	0.02	20	0.80
2	70	0.01	25	0.70
3	55	0.0	30	0.05
4	60	0.1	45	0.26

$$Y = b_0 + b_1x_1 + b_2x_2 + b_3x_3$$

$$Y = b_0 + b_1x_1 + b_2x_2 + b_3x_3$$

No	Vehicle speed (mph) (x_1)	Alcohol level (x_2)	Age (x_3)	Probability of Car Accident (Y)
1	80	0.02	20	0.80
2	70	0.01	25	0.70
3	55	0.0	30	0.05
4	60	0.1	45	0.26

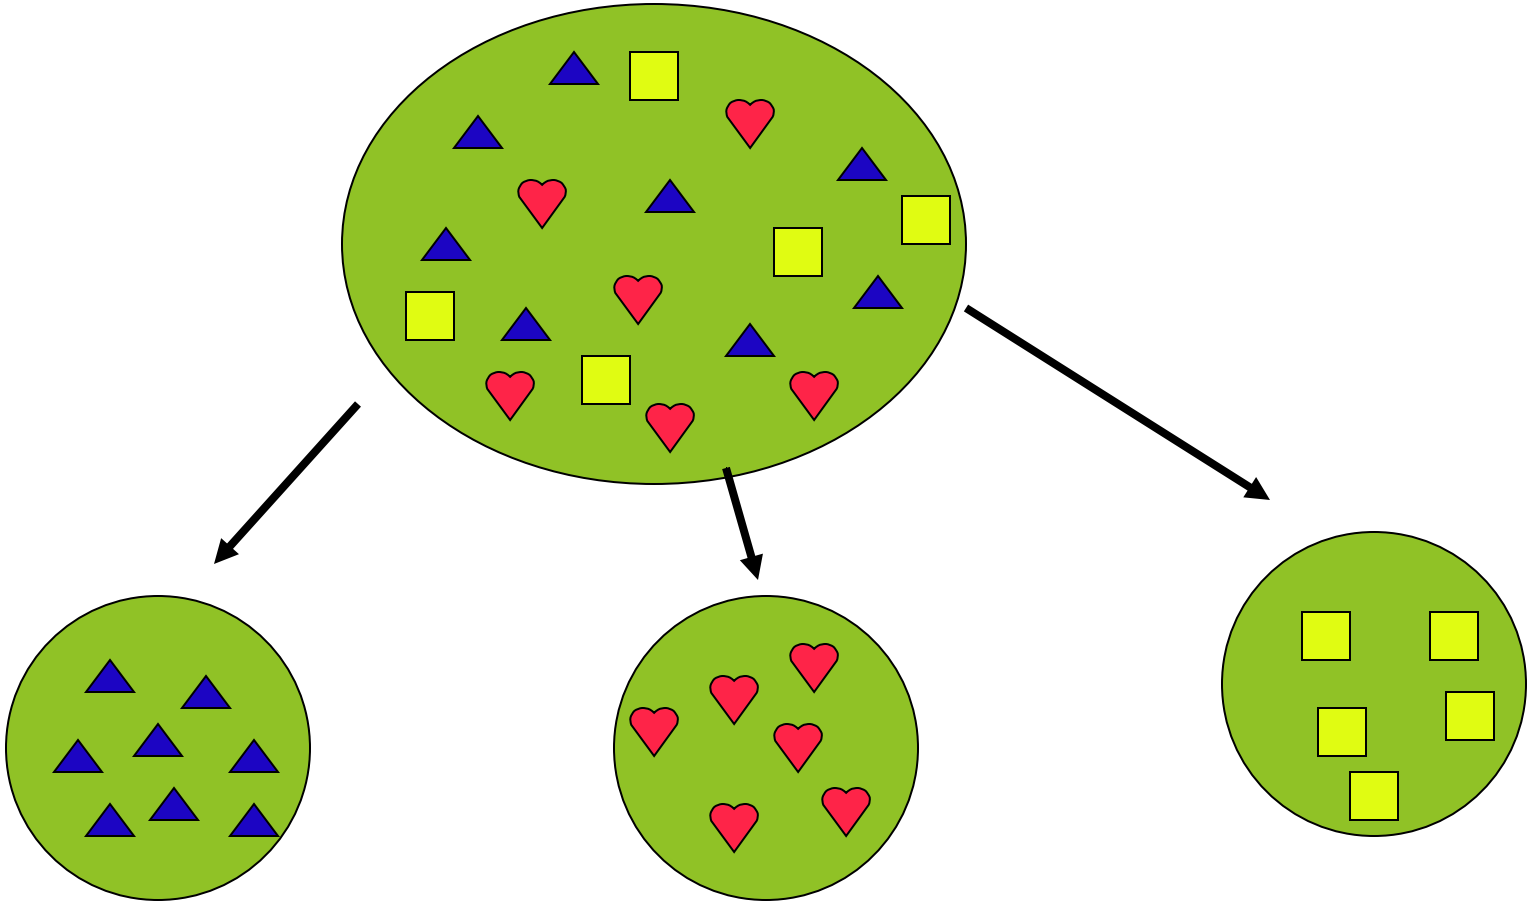
$$Y = 0.002 + 0.024x_1 + 1.04\ x_2 - 0.012\ x_3$$

Data Mining Process

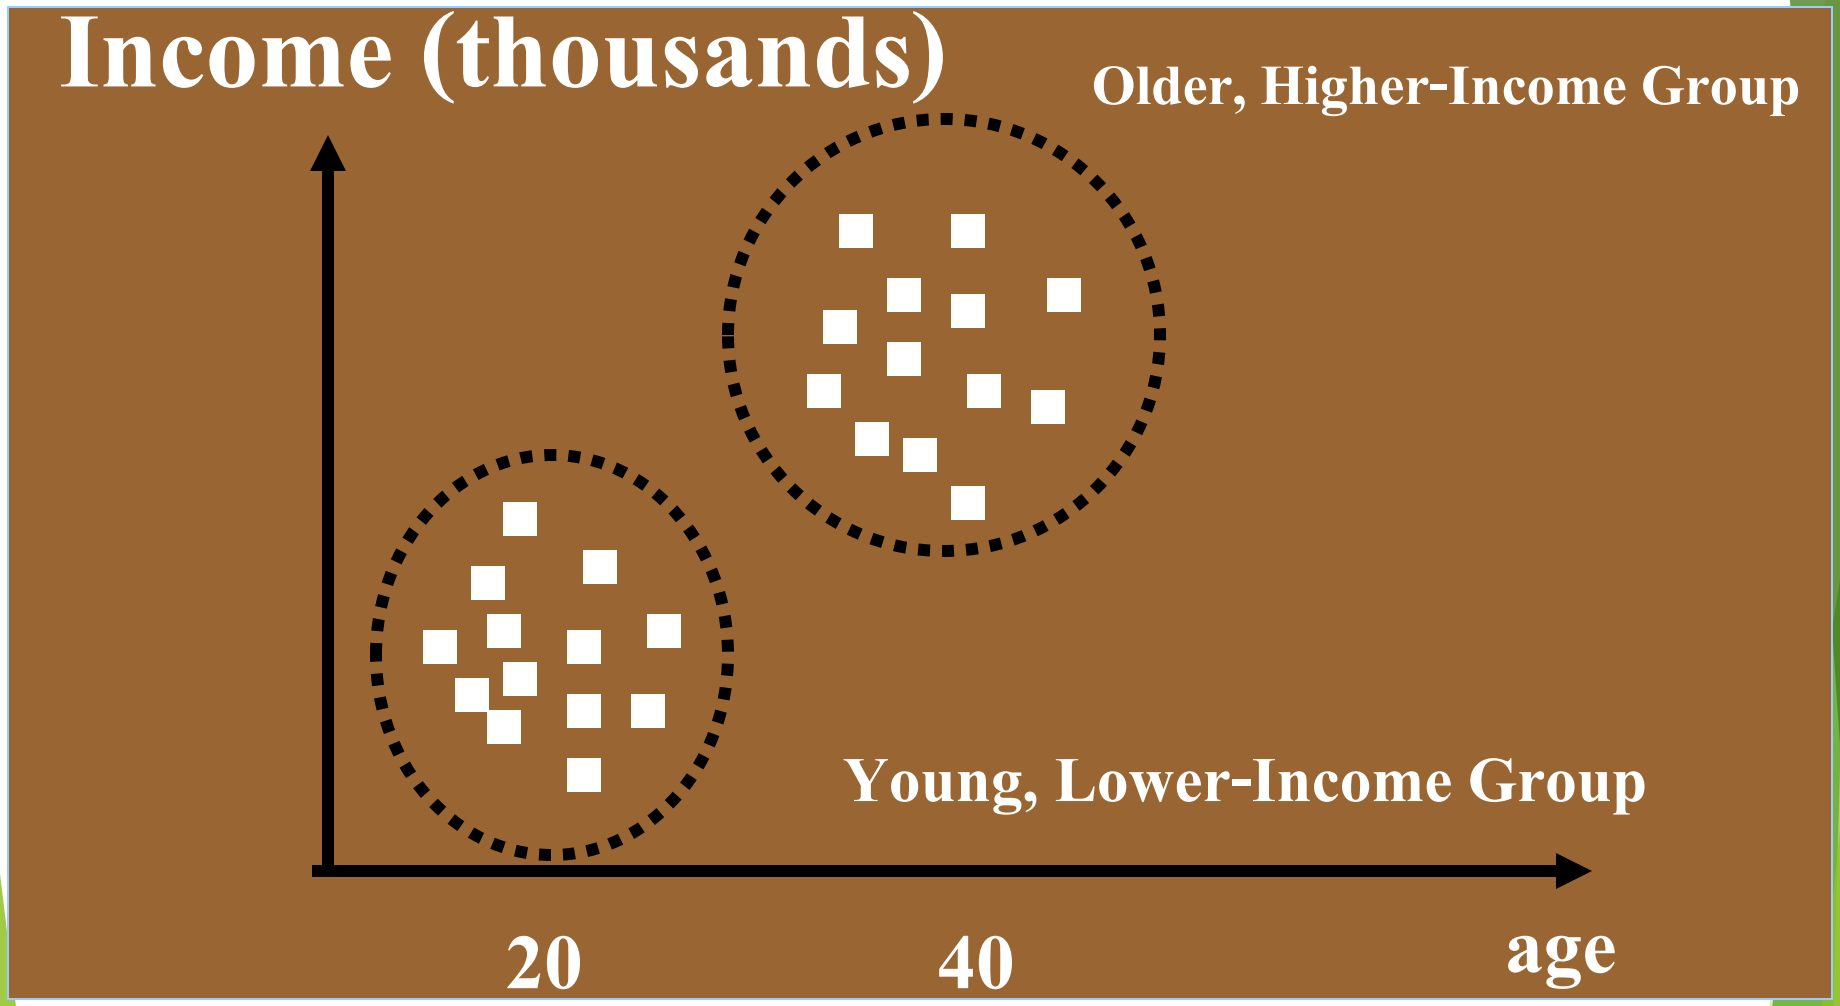
2. Database Segmentation

- Clustering
  - The goal of database segmentation is to partition a database into segments of similar records, that is records that share number of properties.
  - เป็นเทคนิคการจัดกลุ่มข้อมูล (คน, สิ่งของ) โดยนำข้อมูลที่มีคุณลักษณะคล้ายคลึงกันมาอยู่ในกลุ่มเดียวกัน และแยกข้อมูลที่มีลักษณะแตกต่างกันออกจากกัน
  - ไม่จำเป็นต้องกำหนดป้ายกำกับกลุ่มไว้ล่วงหน้า (Unsupervised Learning) โดยอัลกอริทึมจะค้นหารูปแบบและกลุ่มที่เหมาะสมจากข้อมูล

Database segmentation



Database segmentation



Data Mining Process

3. Link Analysis

- Associations Discovery (การค้นหากฎความสัมพันธ์)

  ค้นหาความสัมพันธ์ระหว่างรายการหรือเหตุการณ์ที่เกิดขึ้นร่วมกัน

- Sequential Pattern Discovery (การค้นหารูปแบบตามลำดับ)

  ค้นหารูปแบบของรายการหรือเหตุการณ์ที่เกิดขึ้นตามลำดับเวลา

Associations Discovery

เป็นเทคนิค Data Mining ที่ใช้ค้นหาความสัมพันธ์ระหว่างรายการหรือคุณลักษณะที่มักปรากฏร่วมกันในชุดข้อมูล เช่น ลูกค้าที่ซื้อผ้าอ้อมสำเร็จรูปมักซื้อเบียร์ร่วมด้วย

Association rule

กฎที่แสดงความสัมพันธ์ระหว่างรายการในรูปแบบ (X → Y) เพื่อแสดงว่ารายการใดมักปรากฏร่วมกัน และความสัมพันธ์ดังกล่าวมีความน่าสนใจมากน้อยเพียงใด

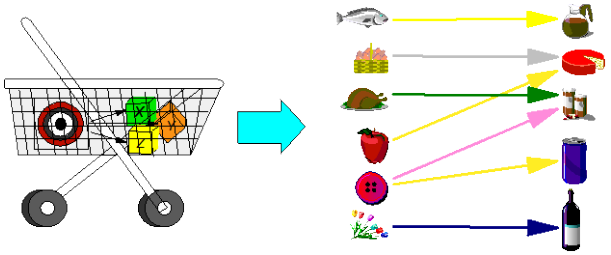
Support: สัดส่วนของธุรกรรมทั้งหมดที่มีรายการ X และ Y ปรากฏร่วมกัน

Confidence: สัดส่วนของธุรกรรมที่มี X แล้วพบ Y ปรากฏร่วมด้วย ใช้แสดงความน่าเชื่อถือของกฎ X → Y

EX: Milk → Sugar

98% of people who buy Milk also buy Sugar.

65% of all grocery shoppers buy both



Data Mining Process

5. Evaluation (การประเมินผล)

เป็นขั้นตอนการประเมินผลลัพธ์จากการทำ Data Mining เพื่อตรวจสอบว่าแบบจำลองที่สร้างขึ้นมีคุณภาพเหมาะสม และสามารถตอบสนองวัตถุประสงค์ทางธุรกิจที่กำหนดไว้ได้หรือไม่

กิจกรรมสำคัญ

- Evaluate Results (แปลผลลัพธ์) :
  - Interpret Results (แปลผลลัพธ์): ตีความผลลัพธ์จากแบบจำลอง เพื่อทำความเข้าใจรูปแบบ แนวโน้ม หรือความสัมพันธ์ที่ค้นพบ และพิจารณาความหมายในบริบทของปัญหา
  - Evaluate Model and Results (ประเมินแบบจำลองและผลลัพธ์): ประเมินคุณภาพและความเหมาะสมของแบบจำลอง รวมถึงตรวจสอบว่าผลลัพธ์สามารถตอบวัตถุประสงค์ของโครงการได้หรือไม่
- Review Process (การทบทวนกระบวนการ):
  - ทบทวนและตรวจสอบขั้นตอนการดำเนินงานที่ผ่านมาทั้งหมด เพื่อค้นหาข้อผิดพลาด ข้อจำกัด หรือประเด็นที่ควรปรับปรุง ซึ่งอาจส่งผลต่อคุณภาพและความน่าเชื่อถือของผลลัพธ์

Data Mining Process

6. Deployment (การนำผลลัพธ์ไปใช้งาน)

นำผลลัพธ์จากการทำเหมืองข้อมูลหรือแบบจำลองที่ผ่านการประเมินแล้วไปประยุกต์ใช้ในการทำงานจริง เพื่อสนับสนุนการตัดสินใจหรือแก้ไขปัญหาทางธุรกิจกิจกรรมสำคัญ

กิจกรรมสำคัญ

- Communicate Results: สื่อสารผลลัพธ์และข้อค้นพบให้ผู้เกี่ยวข้องเข้าใจ เช่น นำเสนอแนวโน้มพฤติกรรมลูกค้า
- Deploy Model: นำแบบจำลองไปใช้งานจริงในระบบหรือกระบวนการทางธุรกิจ เช่น สร้างระบบพยากรณ์ยอดขาย, ใช้ผลการวิเคราะห์จัดโปรโมชัน
- Monitor and Maintain: ติดตามผลการใช้งานและประสิทธิภาพของแบบจำลอง พร้อมปรับปรุงเมื่อข้อมูลหรือสถานการณ์เปลี่ยนแปลง

Data Mining Process

1. Business Understanding
ทำความเข้าใจปัญหาทางธุรกิจ
และกำหนดวัตถุประสงค์



2. Data Understanding
รวบรวมข้อมูลและสำรวจข้อมูล
ทำความเข้าใจลักษณะของข้อมูล่



3. Data Preparation
คัดเลือก ทำความสะอาด
และแปลงข้อมูล



4. Modeling
เลือกเทคนิคการทำเหมืองข้อมูล
และสร้างแบบจำลอง



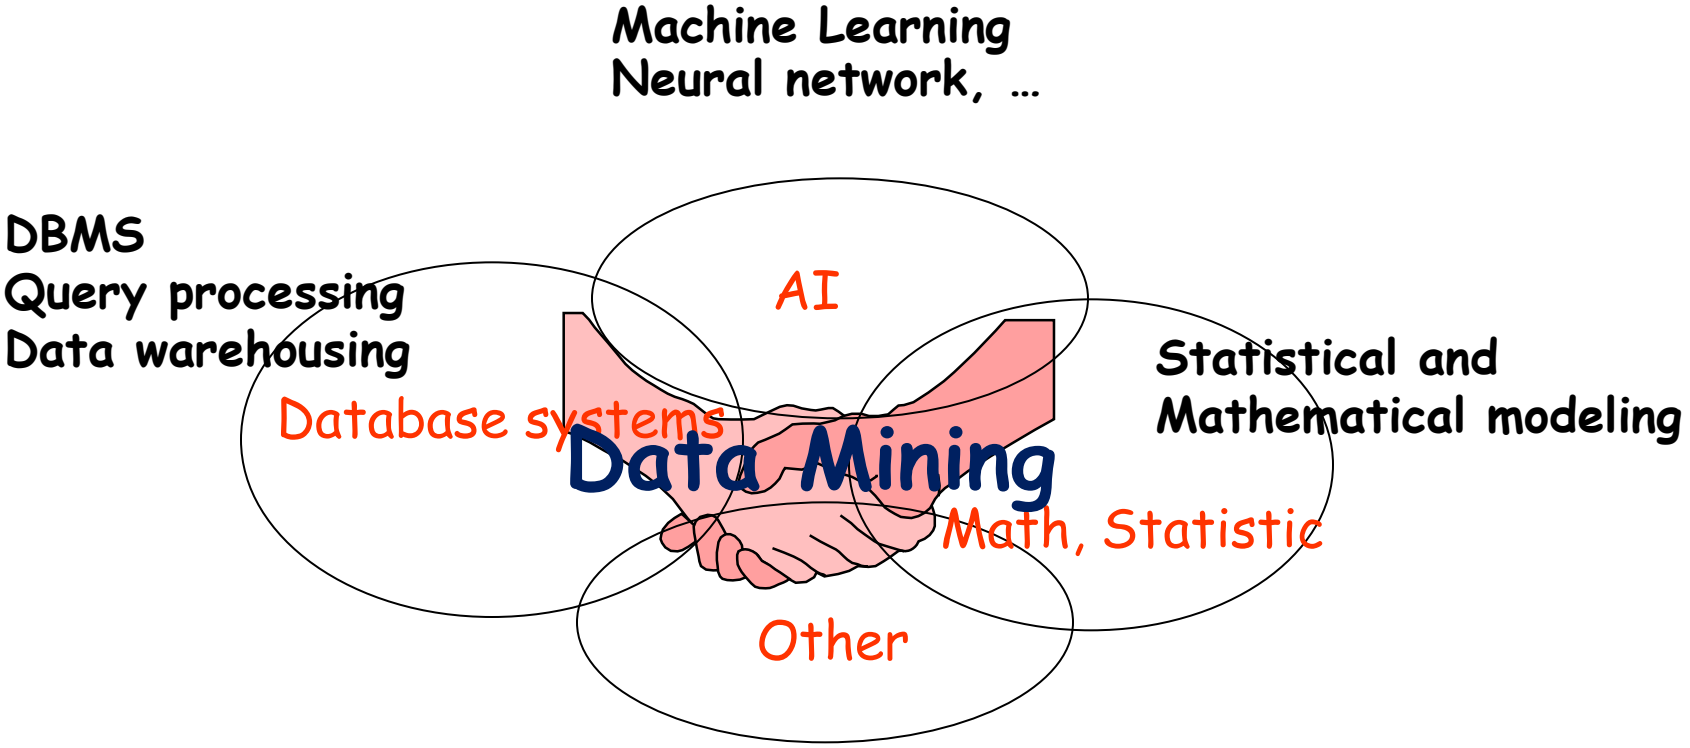
5. Evaluation
แปลผลและประเมินผลว่า
สอดคล้องกับวัตถุประสงค์หรือไม่



6. Deployment
นำผลลัพธ์หรือแบบจำลองไปใช้งานจริง
และติดตามผล



Data mining is multidisciplinary



Data Mining Software

1. Database-integrated Data Mining Software

- Microsoft SQL Server Analysis Services – Data Mining (ยกเลิกใน SQL Server 2022)
- Oracle Data Mining (ชื่อเดิม; ปัจจุบันใช้ Oracle Machine Learning for SQL)

2. Statistical and Analytics Software

- SAS Enterprise Miner
- IBM SPSS Modeler (ชื่อเดิม Clementine)

Data Mining Software

- SAS Enterprise Miner

